

Machine Learning Techniques - Homework 3

資工四 B05902023 李澤諺

Deep Learning Techniques

1. (以下皆為在已知 $\mathbf{x}^{(l-1)}$ 的條件下進行推導，為簡單起見，以下將 $x_i^{(l-1)}$ 皆視為 constant，而省去 conditional probability、conditional distribution function、conditional density function、conditional expectation 的符號)

因為

$$\begin{aligned}\mathbb{E}[s_j^{(l)}] &= \mathbb{E}\left[\sum_{i=1}^{d^{(l-1)}} w_{ij}^{(l)} x_i^{(l-1)}\right] \\ &= \sum_{i=1}^{d^{(l-1)}} \mathbb{E}[w_{ij}^{(l)} x_i^{(l-1)}] \\ &= \sum_{i=1}^{d^{(l-1)}} \mathbb{E}[w_{ij}^{(l)}] \cdot x_i^{(l-1)} \\ &= \sum_{i=1}^{d^{(l-1)}} 0 \cdot x_i^{(l-1)} = 0\end{aligned}$$

因此可得 $s_j^{(l)}$ 為 zero-mean。接著， $\forall n \in \mathbb{N}$ 且 $2 \leq n \leq d^{(l)}$ ，任取 n 個 random variable $s_{j_1}^{(l)}, s_{j_2}^{(l)}, \dots, s_{j_n}^{(l)}$ ，令 $s_{j_k}^{(l)}$ 的 distribution function 和 density function 分別為 $F_{j_k}(t_{j_k})$ 和 $f_{j_k}(t_{j_k})$ ， $s_{j_1}^{(l)}, s_{j_2}^{(l)}, \dots, s_{j_n}^{(l)}$ 的 joint distribution function 和 joint density function 分別為 $F_{j_1 j_2 \dots j_n}(t_{j_1}, t_{j_2}, \dots, t_{j_n})$ 和 $f_{j_1 j_2 \dots j_n}(t_{j_1}, t_{j_2}, \dots, t_{j_n})$ ，並令 $\mathbf{w}_{j_k} = (w_{1j_k}^{(l)}, w_{2j_k}^{(l)}, \dots, w_{d^{(l-1)}j_k}^{(l)})$ ，其 joint density function 為 $g_{j_k}(\mathbf{u}_{j_k}) = g_{j_k}(u_{j_k1}, u_{j_k2}, \dots, u_{j_k d^{(l-1)}})$ ， $\mathbf{w}_{j_1}, \mathbf{w}_{j_2}, \dots, \mathbf{w}_{j_n}$ 的 joint density function 為 $g_{j_1 j_2 \dots j_n}(\mathbf{u}_{j_1}, \mathbf{u}_{j_2}, \dots, \mathbf{u}_{j_n})$ ，並且， $\forall t_{j_k} \in \mathbb{R}$ ，令 $A_{j_k} = \left\{ \mathbf{w}_{j_k} \mid \sum_{i=1}^{d^{(l-1)}} w_{ij_k}^{(l)} x_i^{(l-1)} \leq t_{j_k} \right\}$ 。注意因為 $\mathbf{w}_{j_1}, \mathbf{w}_{j_2}, \dots, \mathbf{w}_{j_n}$ 為 independent random vector，所以

$$g_{j_1 j_2 \dots j_n}(\mathbf{u}_{j_1}, \mathbf{u}_{j_2}, \dots, \mathbf{u}_{j_n}) = g_{j_1}(\mathbf{u}_{j_1}) g_{j_2}(\mathbf{u}_{j_2}) \dots g_{j_n}(\mathbf{u}_{j_n})$$

因此可得

$$\begin{aligned}
& F_{j_1 j_2 \dots j_n} (t_{j_1}, t_{j_2}, \dots, t_{j_n}) \\
&= P \left(s_{j_1}^{(l)} \leq t_{j_1}, s_{j_2}^{(l)} \leq t_{j_2}, \dots, s_{j_n}^{(l)} \leq t_{j_n} \right) \\
&= P \left(\sum_{i=1}^{d^{(l-1)}} w_{ij_1}^{(l)} x_i^{(l-1)} \leq t_{j_1}, \sum_{i=1}^{d^{(l-1)}} w_{ij_2}^{(l)} x_i^{(l-1)} \leq t_{j_2}, \dots, \sum_{i=1}^{d^{(l-1)}} w_{ij_n}^{(l)} x_i^{(l-1)} \leq t_{j_n} \right) \\
&= P (\mathbf{w}_{j_1} \in A_{j_1}, \mathbf{w}_{j_2} \in A_{j_2}, \dots, \mathbf{w}_{j_n} \in A_{j_n}) \\
&= \int_{A_{j_1} \times A_{j_2} \times \dots \times A_{j_n}} g_{j_1 j_2 \dots j_n} (\mathbf{u}_{j_1}, \mathbf{u}_{j_2}, \dots, \mathbf{u}_{j_n}) d\mathbf{u}_{j_1} d\mathbf{u}_{j_2} \dots d\mathbf{u}_{j_n} \\
&= \int_{A_{j_1} \times A_{j_2} \times \dots \times A_{j_n}} g_{j_1} (\mathbf{u}_{j_1}) g_{j_2} (\mathbf{u}_{j_2}) \dots g_{j_n} (\mathbf{u}_{j_n}) d\mathbf{u}_{j_1} d\mathbf{u}_{j_2} \dots d\mathbf{u}_{j_n} \\
&= \int_{A_{j_1}} g_{j_1} (\mathbf{u}_{j_1}) d\mathbf{u}_{j_1} \int_{A_{j_2}} g_{j_2} (\mathbf{u}_{j_2}) d\mathbf{u}_{j_2} \dots \int_{A_{j_n}} g_{j_n} (\mathbf{u}_{j_n}) d\mathbf{u}_{j_n} \\
&= P (\mathbf{w}_{j_1} \in A_{j_1}) P (\mathbf{w}_{j_2} \in A_{j_2}) \dots P (\mathbf{w}_{j_n} \in A_{j_n}) \\
&= P \left(\sum_{i=1}^{d^{(l-1)}} w_{ij_1}^{(l)} x_i^{(l-1)} \leq t_{j_1} \right) P \left(\sum_{i=1}^{d^{(l-1)}} w_{ij_2}^{(l)} x_i^{(l-1)} \leq t_{j_2} \right) \dots \\
&\quad P \left(\sum_{i=1}^{d^{(l-1)}} w_{ij_n}^{(l)} x_i^{(l-1)} \leq t_{j_n} \right) \\
&= P \left(s_{j_1}^{(l)} \leq t_{j_1} \right) P \left(s_{j_2}^{(l)} \leq t_{j_2} \right) \dots P \left(s_{j_n}^{(l)} \leq t_{j_n} \right) \\
&= F_{j_1} (t_{j_1}) F_{j_2} (t_{j_2}) \dots F_{j_n} (t_{j_n})
\end{aligned}$$

故

$$\begin{aligned}
& f_{j_1 j_2 \dots j_n} (t_{j_1}, t_{j_2}, \dots, t_{j_n}) \\
&= \frac{\partial^n}{\partial t_{j_1} \partial t_{j_2} \dots \partial t_{j_n}} F_{j_1 j_2 \dots j_n} (t_{j_1}, t_{j_2}, \dots, t_{j_n}) \\
&= \frac{\partial^n}{\partial t_{j_1} \partial t_{j_2} \dots \partial t_{j_n}} F_{j_1} (t_{j_1}) F_{j_2} (t_{j_2}) \dots F_{j_n} (t_{j_n}) \\
&= f_{j_1} (t_{j_1}) f_{j_2} (t_{j_2}) \dots f_{j_n} (t_{j_n})
\end{aligned}$$

由此可得 $s_1^{(l)}, s_2^{(l)}, \dots, s_{d^{(l)}}^{(l)}$ 爲 independent。

2. 因爲

$$\begin{aligned} Var\left(x_i^{(l-1)}\right) &= \mathbb{E}\left[\left(x_i^{(l-1)}\right)^2\right] - \mathbb{E}\left[x_i^{(l-1)}\right]^2 \\ \sigma_x^2 &= \mathbb{E}\left[\left(x_i^{(l-1)}\right)^2\right] - \bar{x}^2 \\ \mathbb{E}\left[\left(x_i^{(l-1)}\right)^2\right] &= \sigma_x^2 + \bar{x}^2 \end{aligned}$$

以及

$$\begin{aligned} Var\left(w_{ij}^{(l)}\right) &= \mathbb{E}\left[\left(w_{ij}^{(l)}\right)^2\right] - \mathbb{E}\left[w_{ij}^{(l)}\right]^2 \\ \sigma_w^2 &= \mathbb{E}\left[\left(w_{ij}^{(l)}\right)^2\right] - 0^2 \\ \mathbb{E}\left[\left(w_{ij}^{(l)}\right)^2\right] &= \sigma_w^2 \end{aligned}$$

所以

$$\begin{aligned} Var\left(s_j^{(l)}\right) &= \mathbb{E}\left[\left(s_j^{(l)}\right)^2\right] - \mathbb{E}\left[s_j^{(l)}\right]^2 \\ &= \mathbb{E}\left[\left(\sum_{i=1}^{d^{(l-1)}} w_{ij}^{(l)} x_i^{(l-1)}\right)^2\right] - 0^2 \\ &= \mathbb{E}\left[\sum_{i=1}^{d^{(l-1)}} \sum_{k=1}^{d^{(l-1)}} w_{ij}^{(l)} w_{kj}^{(l)} x_i^{(l-1)} x_k^{(l-1)}\right] \\ &= \mathbb{E}\left[\sum_{i=1}^{d^{(l-1)}} \left(w_{ij}^{(l)}\right)^2 \left(x_i^{(l-1)}\right)^2 + \sum_{i \neq k} w_{ij}^{(l)} w_{kj}^{(l)} x_i^{(l-1)} x_k^{(l-1)}\right] \\ &= \sum_{i=1}^{d^{(l-1)}} \mathbb{E}\left[\left(w_{ij}^{(l)}\right)^2 \left(x_i^{(l-1)}\right)^2\right] + \sum_{i \neq k} \mathbb{E}\left[w_{ij}^{(l)} w_{kj}^{(l)} x_i^{(l-1)} x_k^{(l-1)}\right] \end{aligned}$$



其中，因爲 independence，因此可得

$$\begin{aligned} Var\left(s_j^{(l)}\right) &= \sum_{i=1}^{d^{(l-1)}} \mathbb{E}\left[\left(w_{ij}^{(l)}\right)^2 \left(x_i^{(l-1)}\right)^2\right] + \sum_{i \neq k} \mathbb{E}\left[w_{ij}^{(l)} w_{kj}^{(l)} x_i^{(l-1)} x_k^{(l-1)}\right] \\ &= \sum_{i=1}^{d^{(l-1)}} \mathbb{E}\left[\left(w_{ij}^{(l)}\right)^2\right] \mathbb{E}\left[\left(x_i^{(l-1)}\right)^2\right] + \\ &\quad \sum_{i \neq k} \mathbb{E}\left[w_{ij}^{(l)}\right] \mathbb{E}\left[w_{kj}^{(l)}\right] \mathbb{E}\left[x_i^{(l-1)}\right] \mathbb{E}\left[x_k^{(l-1)}\right] \end{aligned}$$

$$\begin{aligned}
&= \sum_{i=1}^{d^{(l-1)}} \sigma_w^2 (\sigma_x^2 + \bar{x}^2) + \sum_{i \neq k} 0 \cdot 0 \cdot \bar{x} \cdot \bar{x} \\
&= d^{(l-1)} \sigma_w^2 (\sigma_x^2 + \bar{x}^2)
\end{aligned}$$

3. 令 $s_i^{(l-1)}$ 的 distribution function 和 density function 分別為 $F_{s_i^{(l-1)}}(t)$ 和 $f_{s_i^{(l-1)}}(t)$ ，而 $x_i^{(l-1)}$ 的 distribution function 和 density function 分別為 $F_{x_i^{(l-1)}}(t)$ 和 $f_{x_i^{(l-1)}}(t)$ 。因為

$$\begin{aligned}
F_{x_i^{(l-1)}}(t) &= P\left(x_i^{(l-1)} \leq t\right) = P\left(\max\left(s_i^{(l-1)}, 0\right) \leq t\right) \\
&= \begin{cases} P\left(s_i^{(l-1)} \leq t\right) = F_{s_i^{(l-1)}}(t) & \text{若 } t \geq 0 \\ 0 & \text{若 } t < 0 \end{cases}
\end{aligned}$$



所以

$$f_{x_i^{(l-1)}}(t) = \frac{d}{dt} F_{x_i^{(l-1)}}(t) = \begin{cases} \frac{d}{dt} F_{s_i^{(l-1)}}(t) = f_{s_i^{(l-1)}}(t) & \text{若 } t > 0 \\ \frac{d}{dt} 0 = 0 & \text{若 } t < 0 \end{cases}$$

因此

$$\begin{aligned} \mathbb{E} \left[\left(x_i^{(l-1)} \right)^2 \right] &= \int_{-\infty}^{\infty} t^2 f_{x_i^{(l-1)}}(t) dt \\ &= \int_{-\infty}^0 t^2 f_{x_i^{(l-1)}}(t) dt + \int_0^{\infty} t^2 f_{x_i^{(l-1)}}(t) dt \\ &= \int_{-\infty}^0 t^2 \cdot 0 dt + \int_0^{\infty} t^2 f_{s_i^{(l-1)}}(t) dt \\ &= \int_0^{\infty} t^2 f_{s_i^{(l-1)}}(t) dt \end{aligned}$$

其中，因為 $s_i^{(l-1)}$ 為 symmetric random variable，所以 $f_{s_i^{(l-1)}}(-t) = f_{s_i^{(l-1)}}(t)$ [ref]，因此 $(-t)^2 f_{s_i^{(l-1)}}(-t) = t^2 f_{s_i^{(l-1)}}(t)$ ，即 $t^2 f_{s_i^{(l-1)}}(t)$ 為 even function，故

$$\begin{aligned} \mathbb{E} \left[\left(x_i^{(l-1)} \right)^2 \right] &= \int_0^{\infty} t^2 f_{s_i^{(l-1)}}(t) dt \\ &= \frac{1}{2} \int_{-\infty}^{\infty} t^2 f_{s_i^{(l-1)}}(t) dt \\ &= \frac{1}{2} \mathbb{E} \left[\left(s_i^{(l-1)} \right)^2 \right] \end{aligned}$$

4. 由第 2 題和第 3 題可知

$$\mathbb{E} \left[\left(s_i^{(l-1)} \right)^2 \right] = 2 \mathbb{E} \left[\left(x_i^{(l-1)} \right)^2 \right] = 2 (\sigma_x^2 + \bar{x}^2)$$

所以

$$\begin{aligned} Var \left(s_i^{(l-1)} \right) &= \mathbb{E} \left[\left(s_i^{(l-1)} \right)^2 \right] - \mathbb{E} \left[s_i^{(l-1)} \right]^2 \\ &= 2 (\sigma_x^2 + \bar{x}^2) - 0^2 \\ &= 2 (\sigma_x^2 + \bar{x}^2) \end{aligned}$$


$$\sigma_x^2 + \bar{x}^2 = \frac{1}{2} Var \left(s_i^{(l-1)} \right)$$

故由第 2 題的結果可得

$$Var \left(s_j^{(l)} \right) = d^{(l-1)} \sigma_w^2 (\sigma_x^2 + \bar{x}^2) = \frac{d^{(l-1)}}{2} \sigma_w^2 Var \left(s_i^{(l-1)} \right)$$

5. 令 $s_j^{(l-1)}$ 的 distribution function 和 density function 分別為 $F_{s_j^{(l-1)}}(t)$ 和 $f_{s_j^{(l-1)}}(t)$ ，而 $x_j^{(l-1)}$ 的 distribution function 和 density function 分別為 $F_{x_j^{(l-1)}}(t)$ 和 $f_{x_j^{(l-1)}}(t)$ 。因為

$$\begin{aligned} F_{x_j^{(l-1)}}(t) &= P\left(x_j^{(l-1)} \leq t\right) = P\left(\max\left(s_j^{(l-1)}, a \cdot s_j^{(l-1)}\right) \leq t\right) \\ &= \begin{cases} P\left(s_j^{(l-1)} \leq t\right) = F_{s_j^{(l-1)}}(t) & \text{若 } t \geq 0 \\ P\left(s_j^{(l-1)} \leq \frac{t}{a}\right) = F_{s_j^{(l-1)}}\left(\frac{t}{a}\right) & \text{若 } t < 0 \end{cases} \end{aligned}$$



所以

$$f_{x_j^{(l-1)}}(t) = \frac{d}{dt} F_{x_j^{(l-1)}}(t) = \begin{cases} \frac{d}{dt} F_{s_j^{(l-1)}}(t) = f_{s_j^{(l-1)}}(t) & \text{若 } t > 0 \\ \frac{d}{dt} F_{s_j^{(l-1)}}\left(\frac{t}{a}\right) = \frac{1}{a} f_{s_j^{(l-1)}}\left(\frac{t}{a}\right) & \text{若 } t < 0 \end{cases}$$

因此

$$\begin{aligned}
\mathbb{E} \left[\left(x_j^{(l-1)} \right)^2 \right] &= \int_{-\infty}^{\infty} t^2 f_{x_j^{(l-1)}}(t) dt \\
&= \int_{-\infty}^0 t^2 f_{x_j^{(l-1)}}(t) dt + \int_0^{\infty} t^2 f_{x_j^{(l-1)}}(t) dt \\
&= \int_{-\infty}^0 \frac{t^2}{a} f_{s_j^{(l-1)}} \left(\frac{t}{a} \right) dt + \int_0^{\infty} t^2 f_{s_j^{(l-1)}}(t) dt
\end{aligned}$$

令 $t = au$ ，則有

$$\begin{aligned}
\mathbb{E} \left[\left(x_j^{(l-1)} \right)^2 \right] &= \int_{-\infty}^0 \frac{t^2}{a} f_{s_j^{(l-1)}} \left(\frac{t}{a} \right) dt + \int_0^{\infty} t^2 f_{s_j^{(l-1)}}(t) dt \\
&= \int_{-\infty}^0 a^2 u^2 f_{s_j^{(l-1)}}(u) du + \int_0^{\infty} t^2 f_{s_j^{(l-1)}}(t) dt \\
&= a^2 \int_{-\infty}^0 t^2 f_{s_j^{(l-1)}}(t) dt + \int_0^{\infty} t^2 f_{s_j^{(l-1)}}(t) dt
\end{aligned}$$

其中，因為 $s_j^{(l-1)}$ 為 symmetric random variable，所以 $f_{s_j^{(l-1)}}(-t) = f_{s_j^{(l-1)}}(t)$ [ref]，因此 $(-t)^2 f_{s_j^{(l-1)}}(-t) = t^2 f_{s_j^{(l-1)}}(t)$ ，即 $t^2 f_{s_j^{(l-1)}}(t)$ 為 even function，故

$$\begin{aligned}
\mathbb{E} \left[\left(x_i^{(l-1)} \right)^2 \right] &= a^2 \int_{-\infty}^0 t^2 f_{s_j^{(l-1)}}(t) dt + \int_0^{\infty} t^2 f_{s_j^{(l-1)}}(t) dt \\
&= \frac{a^2}{2} \int_{-\infty}^{\infty} t^2 f_{s_j^{(l-1)}}(t) dt + \frac{1}{2} \int_{-\infty}^{\infty} t^2 f_{s_j^{(l-1)}}(t) dt \\
&= \frac{a^2 + 1}{2} \int_{-\infty}^{\infty} t^2 f_{s_j^{(l-1)}}(t) dt \\
&= \frac{a^2 + 1}{2} \mathbb{E} \left[\left(s_j^{(l-1)} \right)^2 \right]
\end{aligned}$$

由上式以及第 2 題，可得

$$\mathbb{E} \left[\left(s_j^{(l-1)} \right)^2 \right] = \frac{2}{a^2 + 1} \mathbb{E} \left[\left(x_i^{(l-1)} \right)^2 \right] = \frac{2}{a^2 + 1} (\sigma_x^2 + \bar{x}^2)$$

所以

$$\begin{aligned}
Var \left(s_i^{(l-1)} \right) &= \mathbb{E} \left[\left(s_i^{(l-1)} \right)^2 \right] - \mathbb{E} \left[s_i^{(l-1)} \right]^2 \\
&= \frac{2}{a^2 + 1} (\sigma_x^2 + \bar{x}^2) - 0^2 \\
&= \frac{2}{a^2 + 1} (\sigma_x^2 + \bar{x}^2)
\end{aligned}$$

$$\sigma_x^2 + \bar{x}^2 = \frac{a^2 + 1}{2} \text{Var} \left(s_i^{(l-1)} \right)$$

故由第 2 題的結果可得

$$\text{Var} \left(s_j^{(l)} \right) = d^{(l-1)} \sigma_w^2 (\sigma_x^2 + \bar{x}^2) = \frac{d^{(l-1)}(a^2 + 1)}{2} \sigma_w^2 \text{Var} \left(s_i^{(l-1)} \right)$$

因此，只要在滿足 Problem 1 到 Problem 4 的所有條件下，並取 $w_{ij}^{(l)}$ 的 variance 為 $\sigma_w^2 = \frac{2}{d^{(l-1)}(a^2+1)}$ ，以此進行 initialization，即可得到 $\text{Var} \left(s_j^{(l)} \right) = \text{Var} \left(s_i^{(l-1)} \right)$ 。

6. 以下說明 $\forall T \in \mathbb{N}$ ， $\mathbf{v}_T = \sum_{t=1}^T \beta^{T-t}(1-\beta)\mathbf{\Delta}_t$ 。當 $T = 1$ 時

$$\begin{aligned} \mathbf{v}_1 &= \beta \mathbf{v}_0 + (1-\beta)\mathbf{\Delta}_1 \\ &= \beta \cdot \mathbf{0} + (1-\beta)\mathbf{\Delta}_1 \\ &= (1-\beta)\mathbf{\Delta}_1 \\ &= \sum_{t=1}^1 \beta^{1-t}(1-\beta)\mathbf{\Delta}_t \end{aligned}$$

所以 $\mathbf{v}_1 = \sum_{t=1}^1 \beta^{1-t}(1-\beta)\mathbf{\Delta}_t$ 成立。設當 $T = k$ 時， $\mathbf{v}_k = \sum_{t=1}^k \beta^{k-t}(1-\beta)\mathbf{\Delta}_t$ 成立，則當 $T = k+1$ 時

$$\begin{aligned} \mathbf{v}_{k+1} &= \beta \mathbf{v}_k + (1-\beta)\mathbf{\Delta}_{k+1} \\ &= \beta \left(\sum_{t=1}^k \beta^{k-t}(1-\beta)\mathbf{\Delta}_t \right) + (1-\beta)\mathbf{\Delta}_{k+1} \\ &= \left(\sum_{t=1}^k \beta^{k-t+1}(1-\beta)\mathbf{\Delta}_t \right) + (1-\beta)\mathbf{\Delta}_{k+1} \\ &= \sum_{t=1}^{k+1} \beta^{k-t+1}(1-\beta)\mathbf{\Delta}_t \end{aligned}$$

所以 $\mathbf{v}_{k+1} = \sum_{t=1}^{k+1} \beta^{k-t+1}(1-\beta)\mathbf{\Delta}_t$ 成立，由數學歸納法可知， $\forall T \in \mathbb{N}$ ，皆有 $\mathbf{v}_T = \sum_{t=1}^T \beta^{T-t}(1-\beta)\mathbf{\Delta}_t$ ，因此可得 $\alpha_t = \beta^{T-t}(1-\beta)$ 。

7. 注意 $0 < \beta < 1$ ，所以 $\log_2 \beta < 0$ ，因此

$$\begin{aligned}\alpha_1 &< \frac{1}{2} \\ \beta^{T-1}(1-\beta) &< \frac{1}{2} \\ \log_2 \beta^{T-1}(1-\beta) &< \log_2 \frac{1}{2} \\ (T-1)\log_2 \beta + \log_2(1-\beta) &< -1 \\ (T-1)\log_2 \beta &< -1 - \log_2(1-\beta) \\ T-1 &> \frac{-1 - \log_2(1-\beta)}{\log_2 \beta} \\ T &> \frac{-1 - \log_2(1-\beta)}{\log_2 \beta} + 1\end{aligned}$$

故可取 $T = \left\lceil \frac{-1 - \log_2(1-\beta)}{\log_2 \beta} + 1 \right\rceil$ 。

8.

$$\alpha'_t = \frac{\alpha_t}{\sum_{t=1}^T \alpha_t} = \frac{\beta^{T-t}(1-\beta)}{\sum_{t=1}^T \beta^{T-t}(1-\beta)} = \frac{\beta^{T-t}(1-\beta)}{\beta^{T-1}(1-\beta) \frac{1-\beta^{-T}}{1-\beta^{-1}}} = \beta^{1-t} \frac{1-\beta^{-1}}{1-\beta^{-T}}$$

9. 注意 $0 < \beta < 1$ ，即 $\beta^{-1} > 1$ ，所以 $1 - \beta^{-T} < 0$ ， $\ln \beta^{-1} > 0$ ，因此

$$\begin{aligned}\alpha'_1 &< \frac{1}{2} \\ \frac{1-\beta^{-1}}{1-\beta^{-T}} &< \frac{1}{2} \\ 2(1-\beta^{-1}) &> 1-\beta^{-T} \\ \beta^{-T} &> 2\beta^{-1} - 1 \\ T \ln \beta^{-1} &> \ln(2\beta^{-1} - 1) \\ T &> \frac{\ln(2\beta^{-1} - 1)}{\ln \beta^{-1}}\end{aligned}$$

故可取 $T = \left\lceil \frac{\ln(2\beta^{-1} - 1)}{\ln \beta^{-1}} \right\rceil$ 。

10. 令

$$D_{\mathbf{w}} = \begin{pmatrix} w_0 & 0 & 0 & \cdots & 0 \\ 0 & w_1 & 0 & \cdots & 0 \\ 0 & 0 & w_2 & \cdots & 0 \\ \vdots & \vdots & \vdots & & \vdots \\ 0 & 0 & 0 & \cdots & w_d \end{pmatrix}$$

則

$$\begin{aligned}
\mathbf{w} \odot \mathbf{p} &= \begin{pmatrix} w_0 \\ w_1 \\ w_2 \\ \vdots \\ w_d \end{pmatrix} \odot \begin{pmatrix} p_0 \\ p_1 \\ p_2 \\ \vdots \\ p_d \end{pmatrix} = \begin{pmatrix} w_0 p_0 \\ w_1 p_1 \\ w_2 p_2 \\ \vdots \\ w_d p_d \end{pmatrix} \\
&= \begin{pmatrix} w_0 & 0 & 0 & \cdots & 0 \\ 0 & w_1 & 0 & \cdots & 0 \\ 0 & 0 & w_2 & \cdots & 0 \\ \vdots & \vdots & \vdots & & \vdots \\ 0 & 0 & 0 & \cdots & w_d \end{pmatrix} \begin{pmatrix} p_0 \\ p_1 \\ p_2 \\ \vdots \\ p_d \end{pmatrix} = D_{\mathbf{w}} \mathbf{p}
\end{aligned}$$

因此

$$\begin{aligned}
&E_{\mathbf{p}} \left[\|\mathbf{y} - X(\mathbf{w} \odot \mathbf{p})\|^2 \right] \\
&= E_{\mathbf{p}} \left[\|\mathbf{y} - XD_{\mathbf{w}}\mathbf{p}\|^2 \right] \\
&= E_{\mathbf{p}} \left[(\mathbf{y} - XD_{\mathbf{w}}\mathbf{p})^T (\mathbf{y} - XD_{\mathbf{w}}\mathbf{p}) \right] \\
&= E_{\mathbf{p}} \left[(\mathbf{y}^T - (XD_{\mathbf{w}}\mathbf{p})^T) (\mathbf{y} - XD_{\mathbf{w}}\mathbf{p}) \right] \\
&= E_{\mathbf{p}} \left[\mathbf{y}^T \mathbf{y} - \mathbf{y}^T (XD_{\mathbf{w}}\mathbf{p}) - (XD_{\mathbf{w}}\mathbf{p})^T \mathbf{y} + (XD_{\mathbf{w}}\mathbf{p})^T (XD_{\mathbf{w}}\mathbf{p}) \right] \\
&= E_{\mathbf{p}} \left[\mathbf{y}^T \mathbf{y} - 2\mathbf{y}^T XD_{\mathbf{w}}\mathbf{p} + \mathbf{p}^T D_{\mathbf{w}}^T X^T XD_{\mathbf{w}}\mathbf{p} \right] \\
&= E_{\mathbf{p}} \left[\mathbf{y}^T \mathbf{y} \right] - E_{\mathbf{p}} \left[2\mathbf{y}^T XD_{\mathbf{w}}\mathbf{p} \right] + E_{\mathbf{p}} \left[\mathbf{p}^T D_{\mathbf{w}}^T X^T XD_{\mathbf{w}}\mathbf{p} \right] \\
&= \mathbf{y}^T \mathbf{y} - 2\mathbf{y}^T XD_{\mathbf{w}}E_{\mathbf{p}}[\mathbf{p}] + E_{\mathbf{p}} \left[\mathbf{p}^T D_{\mathbf{w}}^T X^T XD_{\mathbf{w}}\mathbf{p} \right]
\end{aligned}$$

注意 $\forall \mathbf{u} = \begin{pmatrix} u_0 \\ u_1 \\ u_2 \\ \vdots \\ u_d \end{pmatrix}, \mathbf{v} = \begin{pmatrix} v_0 \\ v_1 \\ v_2 \\ \vdots \\ v_d \end{pmatrix} \in \mathbb{R}^{d+1}$, 皆有

$$\begin{aligned}
\mathbf{u}^T \mathbf{v} &= u_0 v_0 + u_1 v_1 + u_2 v_2 + \cdots + u_d v_d \\
&= tr \begin{pmatrix} u_0 v_0 & u_0 v_1 & u_0 v_2 & \cdots & u_0 v_d \\ u_1 v_0 & u_1 v_1 & u_1 v_2 & \cdots & u_1 v_d \\ u_2 v_0 & u_2 v_1 & u_2 v_2 & \cdots & u_2 v_d \\ \vdots & \vdots & \vdots & & \vdots \\ u_d v_0 & u_d v_1 & u_d v_2 & \cdots & u_d v_d \end{pmatrix} = tr(\mathbf{u} \mathbf{v}^T)
\end{aligned}$$

因此可得

$$\begin{aligned}
& E_{\mathbf{p}} \left[\|\mathbf{y} - X(\mathbf{w} \odot \mathbf{p})\|^2 \right] \\
&= \mathbf{y}^T \mathbf{y} - 2\mathbf{y}^T X D_{\mathbf{w}} E_{\mathbf{p}} [\mathbf{p}] + E_{\mathbf{p}} [\mathbf{p}^T D_{\mathbf{w}}^T X^T X D_{\mathbf{w}} \mathbf{p}] \\
&= \mathbf{y}^T \mathbf{y} - 2\mathbf{y}^T X D_{\mathbf{w}} E_{\mathbf{p}} [\mathbf{p}] + E_{\mathbf{p}} \left[(D_{\mathbf{w}}^T X^T X D_{\mathbf{w}} \mathbf{p})^T \mathbf{p} \right] \\
&= \mathbf{y}^T \mathbf{y} - 2\mathbf{y}^T X D_{\mathbf{w}} E_{\mathbf{p}} [\mathbf{p}] + E_{\mathbf{p}} [tr(D_{\mathbf{w}}^T X^T X D_{\mathbf{w}} \mathbf{p} \mathbf{p}^T)] \\
&= \mathbf{y}^T \mathbf{y} - 2\mathbf{y}^T X D_{\mathbf{w}} E_{\mathbf{p}} [\mathbf{p}] + tr(E_{\mathbf{p}} [D_{\mathbf{w}}^T X^T X D_{\mathbf{w}} \mathbf{p} \mathbf{p}^T]) \\
&= \mathbf{y}^T \mathbf{y} - 2\mathbf{y}^T X D_{\mathbf{w}} E_{\mathbf{p}} [\mathbf{p}] + tr(D_{\mathbf{w}}^T X^T X D_{\mathbf{w}} E_{\mathbf{p}} [\mathbf{p} \mathbf{p}^T])
\end{aligned}$$

其中，因爲

$$E_{\mathbf{p}} [p_i] = 0 \cdot P(p_i = 0) + 1 \cdot P(p_i = 1) = 0 \cdot \frac{1}{2} + 1 \cdot \frac{1}{2} = \frac{1}{2}$$

$$E_{\mathbf{p}} [p_i p_j] = 0 \cdot P(p_i p_j = 0) + 1 \cdot P(p_i p_j = 1) = \begin{cases} 0 \cdot \frac{3}{4} + 1 \cdot \frac{1}{4} = \frac{1}{4} & \text{若 } i \neq j \\ 0 \cdot \frac{1}{2} + 1 \cdot \frac{1}{2} = \frac{1}{2} & \text{若 } i = j \end{cases}$$

所以

$$\begin{aligned}
E_{\mathbf{p}} [\mathbf{p}] &= E_{\mathbf{p}} \left[\begin{pmatrix} p_0 \\ p_1 \\ p_2 \\ \vdots \\ p_d \end{pmatrix} \right] = \begin{pmatrix} \frac{1}{2} \\ \frac{1}{2} \\ \frac{1}{2} \\ \vdots \\ \frac{1}{2} \end{pmatrix} = \frac{1}{2} \mathbf{1} \\
E_{\mathbf{p}} [\mathbf{p} \mathbf{p}^T] &= E_{\mathbf{p}} \left[\begin{pmatrix} p_0 p_0 & p_0 p_1 & p_0 p_2 & \cdots & p_0 p_d \\ p_1 p_0 & p_1 p_1 & p_1 p_2 & \cdots & p_1 p_d \\ p_2 p_0 & p_2 p_1 & p_2 p_2 & \cdots & p_2 p_d \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ p_d p_0 & p_d p_1 & p_d p_2 & \cdots & p_d p_d \end{pmatrix} \right] \\
&= \begin{pmatrix} \frac{1}{2} & \frac{1}{4} & \frac{1}{4} & \cdots & \frac{1}{4} \\ \frac{1}{4} & \frac{1}{2} & \frac{1}{4} & \cdots & \frac{1}{4} \\ \frac{1}{4} & \frac{1}{4} & \frac{1}{2} & \cdots & \frac{1}{4} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ \frac{1}{4} & \frac{1}{4} & \frac{1}{4} & \cdots & \frac{1}{2} \end{pmatrix} = \frac{1}{4} \mathbf{1} \mathbf{1}^T + \frac{1}{4} I
\end{aligned}$$

此外，注意

$$D_{\mathbf{w}} \mathbf{1} = \begin{pmatrix} w_0 & 0 & 0 & \cdots & 0 \\ 0 & w_1 & 0 & \cdots & 0 \\ 0 & 0 & w_2 & \cdots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \cdots & w_d \end{pmatrix} \begin{pmatrix} 1 \\ 1 \\ 1 \\ \vdots \\ 1 \end{pmatrix} = \begin{pmatrix} w_0 \\ w_1 \\ w_2 \\ \vdots \\ w_d \end{pmatrix} = \mathbf{w}$$

故

$$\begin{aligned}
& E_{\mathbf{p}} \left[\|\mathbf{y} - X(\mathbf{w} \odot \mathbf{p})\|^2 \right] \\
&= \mathbf{y}^T \mathbf{y} - 2\mathbf{y}^T X D_{\mathbf{w}} E_{\mathbf{p}} [\mathbf{p}] + \text{tr} (D_{\mathbf{w}}^T X^T X D_{\mathbf{w}} E_{\mathbf{p}} [\mathbf{p} \mathbf{p}^T]) \\
&= \mathbf{y}^T \mathbf{y} - 2\mathbf{y}^T X D_{\mathbf{w}} \cdot \frac{1}{2} \mathbf{1} + \text{tr} \left(D_{\mathbf{w}}^T X^T X D_{\mathbf{w}} \left(\frac{1}{4} \mathbf{1} \mathbf{1}^T + \frac{1}{4} I \right) \right) \\
&= \mathbf{y}^T \mathbf{y} - \mathbf{y}^T X D_{\mathbf{w}} \mathbf{1} + \text{tr} \left(\frac{1}{4} D_{\mathbf{w}}^T X^T X D_{\mathbf{w}} \mathbf{1} \mathbf{1}^T + \frac{1}{4} D_{\mathbf{w}}^T X^T X D_{\mathbf{w}} \right) \\
&= \mathbf{y}^T \mathbf{y} - \mathbf{y}^T X \mathbf{w} + \frac{1}{4} \text{tr} (D_{\mathbf{w}}^T X^T X D_{\mathbf{w}} \mathbf{1} \mathbf{1}^T) + \frac{1}{4} \text{tr} (D_{\mathbf{w}}^T X^T X D_{\mathbf{w}}) \\
&= \mathbf{y}^T \mathbf{y} - (X^T \mathbf{y})^T \mathbf{w} + \frac{1}{4} \text{tr} ((D_{\mathbf{w}}^T X^T X D_{\mathbf{w}} \mathbf{1}) \mathbf{1}^T) + \frac{1}{4} \text{tr} (D_{\mathbf{w}}^T X^T X D_{\mathbf{w}}) \\
&= \mathbf{y}^T \mathbf{y} - \mathbf{w}^T X^T \mathbf{y} + \frac{1}{4} (D_{\mathbf{w}}^T X^T X D_{\mathbf{w}} \mathbf{1})^T \mathbf{1} + \frac{1}{4} \text{tr} (D_{\mathbf{w}}^T X^T X D_{\mathbf{w}}) \\
&= \mathbf{y}^T \mathbf{y} - \mathbf{w}^T X^T \mathbf{y} + \frac{1}{4} \mathbf{1}^T D_{\mathbf{w}}^T X^T X D_{\mathbf{w}} \mathbf{1} + \frac{1}{4} \text{tr} (D_{\mathbf{w}}^T X^T X D_{\mathbf{w}}) \\
&= \mathbf{y}^T \mathbf{y} - \mathbf{w}^T X^T \mathbf{y} + \frac{1}{4} (D_{\mathbf{w}} \mathbf{1})^T X^T X (D_{\mathbf{w}} \mathbf{1}) + \frac{1}{4} \text{tr} (D_{\mathbf{w}}^T X^T X D_{\mathbf{w}}) \\
&= \mathbf{y}^T \mathbf{y} - \mathbf{w}^T X^T \mathbf{y} + \frac{1}{4} \mathbf{w}^T X^T X \mathbf{w} + \frac{1}{4} \text{tr} (D_{\mathbf{w}}^T X^T X D_{\mathbf{w}})
\end{aligned}$$

其中，若令 $\|\cdot\|_F$ 爲 Frobenius norm，則

$$\begin{aligned}
& \text{tr} (D_{\mathbf{w}}^T X^T X D_{\mathbf{w}}) \\
&= \text{tr} ((X D_{\mathbf{w}})^T (X D_{\mathbf{w}})) = \|X D_{\mathbf{w}}\|_F^2 \\
&= \left\| \begin{pmatrix} x_{10} & x_{11} & x_{12} & \cdots & x_{1d} \\ x_{20} & x_{21} & x_{22} & \cdots & x_{2d} \\ x_{30} & x_{31} & x_{32} & \cdots & x_{3d} \\ \vdots & \vdots & \vdots & & \vdots \\ x_{N0} & x_{N1} & x_{N2} & \cdots & x_{Nd} \end{pmatrix} \begin{pmatrix} w_0 & 0 & 0 & \cdots & 0 \\ 0 & w_1 & 0 & \cdots & 0 \\ 0 & 0 & w_2 & \cdots & 0 \\ \vdots & \vdots & \vdots & & \vdots \\ 0 & 0 & 0 & \cdots & w_d \end{pmatrix} \right\|_F^2 \\
&= \left\| \begin{pmatrix} w_0 x_{10} & w_1 x_{11} & w_2 x_{12} & \cdots & w_d x_{1d} \\ w_0 x_{20} & w_1 x_{21} & w_2 x_{22} & \cdots & w_d x_{2d} \\ w_0 x_{30} & w_1 x_{31} & w_2 x_{32} & \cdots & w_d x_{3d} \\ \vdots & \vdots & \vdots & & \vdots \\ w_0 x_{N0} & w_1 x_{N1} & w_2 x_{N2} & \cdots & w_d x_{Nd} \end{pmatrix} \right\|_F^2 \\
&= \sum_{i=0}^d \sum_{j=1}^N (w_i x_{ji})^2 = \sum_{i=0}^d \sum_{j=1}^N w_i^2 x_{ji}^2 = \sum_{i=0}^d \left(\sum_{j=1}^N x_{ji}^2 \right) w_i^2
\end{aligned}$$

接著，利用 quadratic form，可得

$$\begin{aligned}
tr(D_{\mathbf{w}}^T X^T X D_{\mathbf{w}}) &= \sum_{i=0}^d \left(\sum_{j=1}^N x_{ji}^2 \right) w_i^2 \\
&= \mathbf{w}^T \begin{pmatrix} \sum_{j=1}^N x_{j0}^2 & 0 & 0 & \cdots & 0 \\ 0 & \sum_{j=1}^N x_{j1}^2 & 0 & \cdots & 0 \\ 0 & 0 & \sum_{j=1}^N x_{j2}^2 & \cdots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \cdots & \sum_{j=1}^N x_{jd}^2 \end{pmatrix} \mathbf{w} \\
&= \mathbf{w}^T \left(\begin{pmatrix} \sum_{j=1}^N x_{j0}^2 & \sum_{j=1}^N x_{j0}x_{j1} & \sum_{j=1}^N x_{j0}x_{j2} & \cdots & \sum_{j=1}^N x_{j0}x_{jd} \\ \sum_{j=1}^N x_{j1}x_{j0} & \sum_{j=1}^N x_{j1}^2 & \sum_{j=1}^N x_{j1}x_{j2} & \cdots & \sum_{j=1}^N x_{j1}x_{jd} \\ \sum_{j=1}^N x_{j2}x_{j0} & \sum_{j=1}^N x_{j2}x_{j1} & \sum_{j=1}^N x_{j2}^2 & \cdots & \sum_{j=1}^N x_{j2}x_{jd} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ \sum_{j=1}^N x_{jd}x_{j0} & \sum_{j=1}^N x_{jd}x_{j1} & \sum_{j=1}^N x_{jd}x_{j2} & \cdots & \sum_{j=1}^N x_{jd}^2 \end{pmatrix} \odot \begin{pmatrix} 1 & 0 & 0 & \cdots & 0 \\ 0 & 1 & 0 & \cdots & 0 \\ 0 & 0 & 1 & \cdots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \cdots & 1 \end{pmatrix} \right) \mathbf{w} \\
&= \mathbf{w}^T \left(\left(\begin{pmatrix} x_{00} & x_{10} & x_{20} & \cdots & x_{N0} \\ x_{01} & x_{11} & x_{21} & \cdots & x_{N1} \\ x_{02} & x_{12} & x_{22} & \cdots & x_{N2} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ x_{0d} & x_{1d} & x_{2d} & \cdots & x_{Nd} \end{pmatrix} \begin{pmatrix} x_{00} & x_{01} & x_{02} & \cdots & x_{0d} \\ x_{10} & x_{11} & x_{12} & \cdots & x_{1d} \\ x_{20} & x_{21} & x_{22} & \cdots & x_{2d} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ x_{N0} & x_{N1} & x_{N2} & \cdots & x_{Nd} \end{pmatrix} \right) \odot \begin{pmatrix} 1 & 0 & 0 & \cdots & 0 \\ 0 & 1 & 0 & \cdots & 0 \\ 0 & 0 & 1 & \cdots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \cdots & 1 \end{pmatrix} \right) \mathbf{w} \\
&= \mathbf{w}^T ((X^T X) \odot I) \mathbf{w}
\end{aligned}$$

因此可得

$$\begin{aligned}
&E_{\mathbf{p}} [\|\mathbf{y} - X(\mathbf{w} \odot \mathbf{p})\|^2] \\
&= \mathbf{y}^T \mathbf{y} - \mathbf{w}^T X^T \mathbf{y} + \frac{1}{4} \mathbf{w}^T X^T X \mathbf{w} + \frac{1}{4} tr(D_{\mathbf{w}}^T X^T X D_{\mathbf{w}}) \\
&= \mathbf{y}^T \mathbf{y} - \mathbf{w}^T X^T \mathbf{y} + \frac{1}{4} \mathbf{w}^T X^T X \mathbf{w} + \frac{1}{4} \mathbf{w}^T ((X^T X) \odot I) \mathbf{w}
\end{aligned}$$

$$= \mathbf{y}^T \mathbf{y} - \mathbf{w}^T X^T \mathbf{y} + \frac{1}{4} \mathbf{w}^T (X^T X + (X^T X) \odot I) \mathbf{w}$$

所以

$$\begin{aligned} & \frac{\partial}{\partial \mathbf{w}} E_{\mathbf{p}} \left[\|\mathbf{y} - X(\mathbf{w} \odot \mathbf{p})\|^2 \right] \\ &= \frac{\partial}{\partial \mathbf{w}} \left(\mathbf{y}^T \mathbf{y} - \mathbf{w}^T X^T \mathbf{y} + \frac{1}{4} \mathbf{w}^T (X^T X + (X^T X) \odot I) \mathbf{w} \right) \\ &= -X^T \mathbf{y} + \frac{1}{2} (X^T X + (X^T X) \odot I) \mathbf{w} \end{aligned}$$

若令

$$\frac{\partial}{\partial \mathbf{w}} E_{\mathbf{p}} \left[\|\mathbf{y} - X(\mathbf{w} \odot \mathbf{p})\|^2 \right] = -X^T \mathbf{y} + \frac{1}{2} (X^T X + (X^T X) \odot I) \mathbf{w} = \mathbf{0}$$

則當 $X^T X + (X^T X) \odot I$ 為 invertible 時，可得

$$\mathbf{w} = 2 (X^T X + (X^T X) \odot I)^{-1} X^T \mathbf{y}$$

而當 $X^T X + (X^T X) \odot I$ 不為 invertible 時，因為 $\forall \mathbf{u} \in \mathbb{R}^{d+1}$ 且 $\mathbf{u} \neq \mathbf{0}$ ，皆有

$$\begin{aligned} & \mathbf{u}^T (X^T X + (X^T X) \odot I) \mathbf{u} \\ &= \mathbf{u}^T X^T X \mathbf{u} + \mathbf{u}^T ((X^T X) \odot I) \mathbf{u} \\ &= (X \mathbf{u})^T (X \mathbf{u}) + \mathbf{u}^T ((X^T X) \odot I) \mathbf{u} \\ &= \|X \mathbf{u}\|^2 + \mathbf{u}^T ((X^T X) \odot I) \mathbf{u} \\ &\geq \mathbf{u}^T ((X^T X) \odot I) \mathbf{u} \end{aligned}$$

其中，由上可知 $\mathbf{u}^T ((X^T X) \odot I) \mathbf{u} = \sum_{i=0}^d \sum_{j=1}^N u_i^2 x_{ji}^2$ ，因此可得

$$\begin{aligned} & \mathbf{u}^T (X^T X + (X^T X) \odot I) \mathbf{u} \\ &\geq \mathbf{u}^T ((X^T X) \odot I) \mathbf{u} = \sum_{i=0}^d \sum_{j=1}^N u_i^2 x_{ji}^2 \geq 0 \end{aligned}$$

所以 $X^T X + (X^T X) \odot I$ 為 positive semi-definite，因此 $E_{\mathbf{p}} \left[\|\mathbf{y} - X(\mathbf{w} \odot \mathbf{p})\|^2 \right]$
 $= \mathbf{y}^T \mathbf{y} - \mathbf{w}^T X^T \mathbf{y} + \frac{1}{4} \mathbf{w}^T (X^T X + (X^T X) \odot I) \mathbf{w}$ 為 convex quadratic function，
 故其必定存在 optimal solution，意即 $\frac{\partial}{\partial \mathbf{w}} E_{\mathbf{p}} \left[\|\mathbf{y} - X(\mathbf{w} \odot \mathbf{p})\|^2 \right] =$
 $-X^T \mathbf{y} + \frac{1}{2} (X^T X + (X^T X) \odot I) \mathbf{w} = \mathbf{0}$ 必定有解，因此可取

$$\mathbf{w} = 2 (X^T X + (X^T X) \odot I)^{\dagger} X^T \mathbf{y}$$

其為 $\frac{\partial}{\partial \mathbf{w}} E_{\mathbf{p}} \left[\|\mathbf{y} - X(\mathbf{w} \odot \mathbf{p})\|^2 \right] = -X^T \mathbf{y} + \frac{1}{2} (X^T X + (X^T X) \odot I) \mathbf{w} = \mathbf{0}$ 一個解。

Aggregation

11. 當 g_1 、 g_2 、 g_3 之中至少有兩者都對某一筆資料分類錯誤時， G 才會將該筆資料分類錯誤，因此，當 g_1 、 g_2 、 g_3 分類錯誤的資料皆不相同時（如 **Figure. 1** 所示）， G 會將所有的資料皆分類正確，此時可得 $E_{out}(G)$ 的最小值為 0，而因為 g_3 的 error 最高，且 $E_{out}(g_3) > E_{out}(g_1) + E_{out}(g_2)$ ，因此若要讓 $E_{out}(G)$ 有最大值，則必須 g_1 和 g_2 分類錯誤的資料皆不同，且被 g_1 或 g_2 分類錯誤的資料也要被 g_3 分類錯誤（如 **Figure. 2** 所示），此時可得 $E_{out}(G)$ 的最大值為 $E_{out}(g_1) + E_{out}(g_2) = 0.08 + 0.16 = 0.24$ ，故 $0 \leq E_{out}(G) \leq 0.24$ 。

0.08		
	0.16	
	0.32	

Figure. 1

0.08		
	0.16	
0.32		

Figure. 2

12. 由於 K 為奇數，因此當 g_1 、 g_2 、 \dots 、 g_K 之中至少有 $\frac{K+1}{2}$ 個 classifier 都對某一筆資料分類錯誤時， G 才會將該筆資料分類錯誤。令資料的數量為 N ，則 g_k 所產生的分類錯誤總共有 $e_k N$ 個，因此 g_1 、 g_2 、 \dots 、 g_K 所產生的分類錯誤總共有 $\sum_{k=1}^K e_k N$ 個，當被 G 分類正確的資料都會被 g_1 、 g_2 、 \dots 、 g_K 分類正確，而被 G 分類錯誤的資料，其僅會被 g_1 、 g_2 、 \dots 、 g_K 之中的 $\frac{K+1}{2}$ 個 classifier 分類錯誤，此時可得會被 G 分類錯誤的資料數目上限為

$$\frac{\sum_{k=1}^K e_k N}{\frac{K+1}{2}} = \frac{2}{K+1} \sum_{k=1}^K e_k N$$

因此可得 $E_{out}(G)$ 的一個上限為

$$\frac{\frac{2}{K+1} \sum_{k=1}^K e_k N}{N} = \frac{2}{K+1} \sum_{k=1}^K e_k$$

13. 首先, $\forall a > 0$, 因為

$$\begin{aligned}
\ln \left(\lim_{N \rightarrow \infty} \left(1 - \frac{a}{N} \right)^{pN} \right) &= \lim_{N \rightarrow \infty} \ln \left(1 - \frac{a}{N} \right)^{pN} \quad (\text{since } \ln(x) \text{ is continuous}) \\
&= \lim_{N \rightarrow \infty} pN \ln \left(1 - \frac{a}{N} \right) \\
&= \lim_{N \rightarrow \infty} \frac{\ln \left(1 - \frac{a}{N} \right)}{\frac{1}{pN}} \quad \left(\text{indeterminate form } \frac{0}{0} \right) \\
&= \lim_{N \rightarrow \infty} \frac{\frac{1}{1 - \frac{a}{N}} \cdot \frac{a}{N^2}}{-\frac{1}{pN^2}} \quad (L'Hopital's \text{ rule}) \\
&= \lim_{N \rightarrow \infty} \frac{-ap}{1 - \frac{a}{N}} = -ap
\end{aligned}$$

所以

$$\lim_{N \rightarrow \infty} \left(1 - \frac{a}{N} \right)^{pN} = e^{-ap}$$

因此, $\forall a > 0$, 當 N 足夠大時, 便有 $\left(1 - \frac{a}{N} \right)^{pN} \approx e^{-ap}$ 。接著開始說明第 13 題。
 若令每一次 sample 的結果之間互為 independent, 則對每一筆資料而言, 其在 sample $N' = pN$ 次之後完全沒有被 sample 到的機率為 $\left(\frac{N-1}{N} \right)^{pN} = \left(1 - \frac{1}{N} \right)^{pN} \approx e^{-p}$, 因此該筆資料至少有被 sample 到一次的機率大約為 $1 - e^{-p}$ 。接著, $\forall i \in \{1, 2, \dots, N\}$, 令 X_i 為第 i 筆資料是否有被 sample 到的 random variable, $X_i = 1$ (成功) 代表第 i 筆資料至少有被 sample 到一次, 而 $X_i = 0$ (失敗) 代表第 i 筆資料完全沒有被 sample 到, 由上可知, $P(X_i = 1) \approx 1 - e^{-p}$, $P(X_i = 0) \approx e^{-p}$, 注意 $\forall k \in \mathbb{N}$ 且 $2 \leq k \leq N$, 考慮任意 k 個 random variable $X_{i_1}, X_{i_2}, \dots, X_{i_k}$, 令 $x_{i_1}, x_{i_2}, \dots, x_{i_k} \in \{0, 1\}$, 並令 s 為其中成功的次數, t 為其中失敗的次數, 因為

$$P(X_{i_1} = x_{i_1})P(X_{i_2} = x_{i_2}) \cdots P(X_{i_k} = x_{i_k}) \approx (1 - e^{-p})^s (e^{-p})^t$$

而由 inclusion-exclusion principle, 可得

$$\begin{aligned}
&P(X_{i_1} = x_{i_1}, X_{i_2} = x_{i_2}, \dots, X_{i_k} = x_{i_k}) \\
&= \left(\frac{N-t}{N} \right)^{pN} - \binom{s}{1} \left(\frac{N-(t+1)}{N} \right)^{pN} + \binom{s}{2} \left(\frac{N-(t+2)}{N} \right)^{pN} - \cdots + \\
&\quad (-1)^s \binom{s}{s} \left(\frac{N-(t+s)}{N} \right)^{pN} \\
&= \left(1 - \frac{t}{N} \right)^{pN} - \binom{s}{1} \left(1 - \frac{t+1}{N} \right)^{pN} + \binom{s}{2} \left(1 - \frac{t+2}{N} \right)^{pN} - \cdots + \\
&\quad (-1)^s \binom{s}{s} \left(1 - \frac{t+s}{N} \right)^{pN} \\
&\approx e^{-tp} - \binom{s}{1} e^{-(t+1)p} + \binom{s}{2} e^{-(t+2)p} - \cdots + (-1)^s \binom{s}{s} e^{-(t+s)p}
\end{aligned}$$

$$\begin{aligned}
&= e^{-tp} \left(1 - \binom{s}{1} e^{-p} + \binom{s}{2} e^{-2p} - \dots + (-1)^s \binom{s}{s} e^{-sp} \right) \\
&= e^{-tp} (1 - e^{-p})^s
\end{aligned}$$

故 $P(X_{i_1} = x_{i_1}, X_{i_2} = x_{i_2}, \dots, X_{i_k} = x_{i_k}) \approx P(X_{i_1} = x_{i_1})P(X_{i_2} = x_{i_2}) \dots P(X_{i_k} = x_{i_k})$ ，意即當 N 足夠大時， X_1, X_2, \dots, X_N 為 independent random variable，因此此時可以將檢驗每一筆資料是否有被 sample 過的過程視為 binomial experiment，而平均來說至少有被 sample 過一次的資料數量，即成功次數的期望值，為 $(1 - e^{-p})N = N - (e^{-p} \cdot N)$ 。

Kernel for Decision Stumps

14. 首先，考慮在 s 和 i 固定的情況下，由於 $\forall \mathbf{x} \in \mathcal{X}$ ， x_i 皆為 integer，因此當 θ 和 $\tilde{\theta}$ 皆在 $(-\infty, L], (L, L+1], (L+1, L+2], \dots, (R-2, R-1], (R-1, R], (R, \infty)$ 之中某一個相同的 interval 時， $g_{s,i,\theta}(\mathbf{x}) = s \cdot \text{sign}(x_i - \theta)$ 和 $g_{s,i,\tilde{\theta}}(\mathbf{x}) = s \cdot \text{sign}(x_i - \tilde{\theta})$ 的值便會相同，即 $g_{s,i,\theta}$ 和 $g_{s,i,\tilde{\theta}}$ 為相同的 decision stump，而當 θ 和 $\tilde{\theta}$ 在 $(-\infty, L], (L, L+1], (L+1, L+2], \dots, (R-2, R-1], (R-1, R], (R, \infty)$ 之中不同的 interval 時，便 $\exists \mathbf{x} \in \mathcal{X}$ 且 $x_i \in (\min(\theta, \tilde{\theta}), \max(\theta, \tilde{\theta}))$ ，使得 $g_{s,i,\theta}(\mathbf{x}) = s \cdot \text{sign}(x_i - \theta)$ 和 $g_{s,i,\tilde{\theta}}(\mathbf{x}) = s \cdot \text{sign}(x_i - \tilde{\theta})$ 的值不同，即 $g_{s,i,\theta}$ 和 $g_{s,i,\tilde{\theta}}$ 為不同的 decision stump，由此可知，在 s 和 i 固定的情況下，decision stump 的數量會和 interval $(-\infty, L], (L, L+1], (L+1, L+2], \dots, (R-2, R-1], (R-1, R], (R, \infty)$ 的數量相同，為 $R - L + 2$ 個。接著，由於 $s \in \{+1, -1\}$ 有 2 個不同的值， $i \in \{1, 2, \dots, d\}$ 有 d 個不同的值，因此不同的 decision stump 數量至多為 $2d(R - L + 2)$ 個，但是當 $s = +1$ 且 $\theta \in (-\infty, L]$ ，以及 $s = -1$ 且 $\theta \in (R, \infty)$ 時， $\forall \mathbf{x} \in \mathcal{X}$ ，皆有 $g_{s,i,\theta}(\mathbf{x}) = s \cdot \text{sign}(x_i - \theta) = +1$ ，因此這 $2d$ 個 decision stump 事實上皆為相同的 decision stump，故多算了 $2d - 1$ 個 decision stump，同理，當 $s = -1$ 且 $\theta \in (-\infty, L]$ ，以及 $s = +1$ 且 $\theta \in (R, \infty)$ 時， $\forall \mathbf{x} \in \mathcal{X}$ ，皆有 $g_{s,i,\theta}(\mathbf{x}) = s \cdot \text{sign}(x_i - \theta) = -1$ ，因此這 $2d$ 個 decision stump 事實上皆為相同的 decision stump，故多算了 $2d - 1$ 個 decision stump，因此可得不同的 decision stump 數量應為

$$2d(R - L + 2) - 2 \times (2d - 1) = 2d(R - L) + 2$$

故當 $d = 4, L = 0, R = 5$ 時，不同的 decision stump 數量為

$$2 \times 4 \times (5 - 0) + 2 = 42$$

15.

$$K_{ds}(\mathbf{x}, \mathbf{x}') = (\phi_{ds}(\mathbf{x}))^T (\phi_{ds}(\mathbf{x}')) = \sum_{g_{s,i,\theta} \in \mathcal{G}} g_{s,i,\theta}(\mathbf{x}) g_{s,i,\theta}(\mathbf{x}')$$

令 $m_i = \min(x_i, x'_i)$, $M_i = \max(x_i, x'_i)$ 。首先，在 s 和 i 固定的情況下，由第 14 題可知，此時有 $R - L + 2$ 個不同的 $g_{s,i,\theta}$ ，其中，當 θ 屬於 $(m_i, m_i + 1]$ 、 $(m_i + 1, m_i + 2]$ 、 \dots 、 $(M_i - 2, M_i - 1]$ 、 $(M_i - 1, M_i]$ 這 $M_i - m_i$ 個 interval 之中的其中一個時， $g_{s,i,\theta}(\mathbf{x}) = s \cdot \text{sign}(x_i - \theta)$ 和 $g_{s,i,\theta}(\mathbf{x}') = s \cdot \text{sign}(x'_i - \theta)$ 異號，意即會有 $M_i - m_i$ 個不同的 $g_{s,i,\theta}$ 使得 $g_{s,i,\theta}(\mathbf{x})g_{s,i,\theta}(\mathbf{x}') = -1$ ，而當 θ 不屬於 $(m_i, m_i + 1]$ 、 $(m_i + 1, m_i + 2]$ 、 \dots 、 $(M_i - 2, M_i - 1]$ 、 $(M_i - 1, M_i]$ 這 $M_i - m_i$ 個 interval 之中的任何一個時， $g_{s,i,\theta}(\mathbf{x}) = s \cdot \text{sign}(x_i - \theta)$ 和 $g_{s,i,\theta}(\mathbf{x}') = s \cdot \text{sign}(x'_i - \theta)$ 同號，意即會有 $(R - L + 2) - (M_i - m_i)$ 個不同的 $g_{s,i,\theta}$ 使得 $g_{s,i,\theta}(\mathbf{x})g_{s,i,\theta}(\mathbf{x}') = +1$ ，因此在 s 和 i 固定的情況下，將 $g_{s,i,\theta}(\mathbf{x})g_{s,i,\theta}(\mathbf{x}')$ 對 θ 作 summation 後可得

$$\begin{aligned} & (M_i - m_i) \times (-1) + ((R - L + 2) - (M_i - m_i)) \times (+1) \\ &= (R - L + 2) - 2(M_i - m_i) = (R - L + 2) - 2|x_i - x'_i| \end{aligned}$$

接著，將上式對 s 和 i 作 summation，可得

$$\begin{aligned} & \sum_{s \in \{+1, -1\}} \sum_{i=1}^d ((R - L + 2) - 2|x_i - x'_i|) \\ &= \sum_{s \in \{+1, -1\}} \left(d(R - L + 2) - 2 \sum_{i=1}^d |x_i - x'_i| \right) \\ &= 2 \left(d(R - L + 2) - 2 \sum_{i=1}^d |x_i - x'_i| \right) \\ &= 2d(R - L + 2) - 4 \sum_{i=1}^d |x_i - x'_i| \end{aligned}$$

令 $\|\cdot\|_1$ 為 L1-norm，則上式可以寫為

$$2d(R - L + 2) - 4\|\mathbf{x} - \mathbf{x}'\|$$

但是當 $s = +1$ 且 $\theta \in (-\infty, L]$ ，以及 $s = -1$ 且 $\theta \in (R, \infty)$ 時， $\forall \mathbf{x} \in \mathcal{X}$ ，皆有 $g_{s,i,\theta}(\mathbf{x}) = s \cdot \text{sign}(x_i - \theta) = +1$ ，因此這 $2d$ 個 $g_{s,i,\theta}$ 事實上皆為相同的 decision stump，故上式多算了 $2d - 1$ 個 $g_{s,i,\theta}(\mathbf{x})g_{s,i,\theta}(\mathbf{x}') = (+1) \times (+1) = 1$ ，同理，當 $s = -1$ 且 $\theta \in (-\infty, L]$ ，以及 $s = +1$ 且 $\theta \in (R, \infty)$ 時， $\forall \mathbf{x} \in \mathcal{X}$ ，皆有 $g_{s,i,\theta}(\mathbf{x}) = s \cdot \text{sign}(x_i - \theta) = -1$ ，因此這 $2d$ 個 $g_{s,i,\theta}$ 事實上皆為相同的 decision stump，故上式多算了 $2d - 1$ 個 $g_{s,i,\theta}(\mathbf{x})g_{s,i,\theta}(\mathbf{x}') = (-1) \times (-1) = 1$ ，因此可得

$$\begin{aligned} K_{ds}(\mathbf{x}, \mathbf{x}') &= \sum_{g_{s,i,\theta} \in \mathcal{G}} g_{s,i,\theta}(\mathbf{x})g_{s,i,\theta}(\mathbf{x}') \\ &= 2d(R - L + 2) - 4\|\mathbf{x} - \mathbf{x}'\| - 2 \times (2d - 1) \\ &= 2d(R - L) + 2 - 4\|\mathbf{x} - \mathbf{x}'\| \end{aligned}$$

16. 首先，在 s 和 i 固定的情況下，若 $\theta, \tilde{\theta} \in [L, R]$ ，則當 $\theta \neq \tilde{\theta}$ 時， $\exists \mathbf{x} \in \mathcal{X}$ 且 x_i 介於 θ 和 $\tilde{\theta}$ 之間，使得 $g_{s,i,\theta}(\mathbf{x}) = s \cdot \text{sign}(x_i - \theta)$ 和 $g_{s,i,\tilde{\theta}}(\mathbf{x}) = s \cdot \text{sign}(x_i - \tilde{\theta})$ 的值不同，即 $g_{s,i,\theta}$ 和 $g_{s,i,\tilde{\theta}}$ 為不同的 decision stump，而若 $\theta \in (-\infty, L)$ ，則 $\forall \mathbf{x} \in \mathcal{X}$ ， $g_{s,i,\theta}(\mathbf{x})$ 和 $g_{s,i,L}(\mathbf{x})$ 的值皆為 $+s$ ，即 $g_{s,i,\theta}$ 和 $g_{s,i,L}$ 為相同的 decision stump，而若 $\theta \in (R, \infty)$ ，則 $\forall \mathbf{x} \in \mathcal{X}$ ， $g_{s,i,\theta}(\mathbf{x})$ 和 $g_{s,i,R+1}(\mathbf{x})$ 的值皆為 $-s$ ，即 $g_{s,i,\theta}$ 和 $g_{s,i,R+1}$ 為相同的 decision stump，由上可知，在 s 和 i 固定的情況下，所有的 decision stump 皆可以由 $\theta \in [L, R] \cup \{R+1\}$ 來唯一決定，因此，將 $g_{s,i,\theta}(\mathbf{x})g_{s,i,\theta}(\mathbf{x}')$ 對 θ 作 integral 時，integral region 為 $[L, R] \cup \{R+1\}$ (注意 $\{R+1\}$ 在 \mathbb{R} 中為 measure zero，因此在 $\theta = R+1$ 上的 integral 為 0，可以不用考慮在 $\theta = R+1$ 上的 integral)，可得

$$\begin{aligned} & \int_L^R g_{s,i,\theta}(\mathbf{x})g_{s,i,\theta}(\mathbf{x}')d\theta \\ &= \int_L^R (s \cdot \text{sign}(x_i - \theta))(s \cdot \text{sign}(x'_i - \theta))d\theta \\ &= \int_L^R \text{sign}(x_i - \theta)\text{sign}(x'_i - \theta)d\theta \end{aligned}$$

其中，令 $m_i = \min(x_i, x'_i)$ 、 $M_i = \max(x_i, x'_i)$ ，當 $\theta \in [m_i, M_i]$ 時，可得 $\text{sign}(x_i - \theta)$ 和 $\text{sign}(x'_i - \theta)$ 同號，即 $\text{sign}(x_i - \theta)\text{sign}(x'_i - \theta) = +1$ ，而當 $\theta \notin [m_i, M_i]$ 時，可得 $\text{sign}(x_i - \theta)$ 和 $\text{sign}(x'_i - \theta)$ 異號，即 $\text{sign}(x_i - \theta)\text{sign}(x'_i - \theta) = -1$ ，因此上式等於

$$\begin{aligned} & \int_L^R \text{sign}(x_i - \theta)\text{sign}(x'_i - \theta)d\theta \\ &= \int_L^{m_i} \text{sign}(x_i - \theta)\text{sign}(x'_i - \theta)d\theta + \\ & \quad \int_{m_i}^{M_i} \text{sign}(x_i - \theta)\text{sign}(x'_i - \theta)d\theta + \\ & \quad \int_{M_i}^R \text{sign}(x_i - \theta)\text{sign}(x'_i - \theta)d\theta \\ &= \int_L^{m_i} (+1)d\theta + \int_{m_i}^{M_i} (-1)d\theta + \int_{M_i}^R (+1)d\theta \\ &= (m_i - L) - (M_i - m_i) + (R - M_i) \\ &= (R - L) - 2(M_i - m_i) \\ &= (R - L) - 2|x_i - x'_i| \end{aligned}$$

接著，將上式對 s 和 i 作 summation，可得

$$\begin{aligned}
& \sum_{s \in \{+1, -1\}} \sum_{i=1}^d ((R-L) - 2|x_i - x'_i|) \\
&= \sum_{s \in \{+1, -1\}} \left(d(R-L) - 2 \sum_{i=1}^d |x_i - x'_i| \right) \\
&= 2d(R-L) - 4 \sum_{i=1}^d |x_i - x'_i|
\end{aligned}$$

令 $\|\cdot\|_1$ 為 L1-norm，則上式可以寫為

$$2d(R-L) - 4\|\mathbf{x} - \mathbf{x}'\|_1$$

因此可得

$$K_{ds}(\mathbf{x}, \mathbf{x}') = (\phi(\mathbf{x}))^T (\phi(\mathbf{x}')) = 2d(R-L) - 4\|\mathbf{x} - \mathbf{x}'\|_1$$

(注意雖然以上過程中會和第 14、15 題一樣考慮到重複的 decision stump，但由於這些重複的 decision stump 個數為 finite，因此在 integral 時其為 measure zero set，也因此不會影響到之後的 summation，故對以上的結果沒有影響)

Yes, A Lighter Homework :-)

17. 其實老師講授的每一個 Lecture 我都很喜歡，因為雖然我之前已經有修過其它的機器學習課程，可能有些內容之前已經學過了，但是老師所講授的內容與方式卻是最深入淺出的，老師儘可能地用淺顯易懂而清晰的方式來授課，讓人很能掌握並深入課程所講授的知識，而且在機器學習基石與技法的課程中，老師有講到許多其它課程中所沒有講授或不同的觀點，因此讓我在這兩個課程之中收穫頗豐，尤其是 Lecture 7: Blending and Bagging 之中，我更是從老師的課程中學到了和以往不同的解釋與觀點，因此是我最喜歡的一個 Lecture。

18. 其實老師講授的每一個 Lecture 我都很喜歡，硬要說的話大概是今年新增的課程內容 Activation in Deep Learning 和 Initialization/Optimization in Deep Learning 等部分吧，雖然老師有上傳手寫的 note 到課程網站方便同學複習，但個人還是比較喜歡看課程投影片來複習，因此有些遺憾，不過整體而言這學期的課程真的非常充實，真的萬分感謝老師的授課！